

로봇 시뮬레이션 환경의 수치 적분 오차 예측을 위한 머신러닝

[2026-1] Machine Learning — 프로젝트 최종 보고서

학번: [12214249] | 이름: [장승우]

인하대학교 [데이터사이언스]

2026년 6월 1일

1. 서론

로봇 제어 분야에서 시뮬레이터는 실제 하드웨어 없이 알고리즘을 설계하고 검증하는 핵심 도구이다. 그러나 시뮬레이터와 실제 환경 사이에는 항상 시뮬레이션-실제 격차(sim-to-real gap)가 존재하며, 이는 실제 배포 시 성능 저하의 주요 원인이 된다. 이 격차는 물리 법칙의 근사 방식, 즉 연속 시간 역학을 이산 시간으로 수치 적분하는 과정에서 발생한다.

Gymnasium의 Pendulum-v1 환경은 단진자의 운동 방정식을 1차 Euler 적분($dt = 0.05$ s)으로 이산화한다. Euler 적분은 계산이 빠르지만 4차 Runge-Kutta(RK4) 방법에 비해 정확도가 낮아, 긴 궤적에서 오차가 누적된다. 이 두 방법 사이의 차이, 즉 적분 오차(integration error)는 현재 상태와 입력 토크의 결정론적 함수이다.

본 프로젝트는 이 적분 오차를 머신러닝 모델로 예측하는 것을 목표로 한다. 학습된 오차 모델은 다음과 같은 응용에 활용될 수 있다:

- 오차 보상(Error Compensation): Euler 적분 결과를 RK4 수준으로 실시간 보정하여 궤적 정확도를 향상.
- Sim-to-Real 전이: 모델 기반 강화학습에서 편향 보정 항으로 활용.
- 적응형 적분: 오차가 큰 상태-입력 조합을 파악하여 가변 시간 간격 전략 수립.

1.1 문제 정의

Gymnasium Pendulum-v1의 상태 관측값($\cos\theta$, $\sin\theta$, $\dot{\theta}$)과 적용 토크(τ)가 주어졌을 때, 2차원 적분 오차 벡터를 예측한다:

```
y = [err_theta, err_theta_dot] = [theta_euler - theta_rk4, thetadot_euler - thetadot_rk4]
```

이는 4개의 스칼라 입력과 2개의 스칼라 출력을 갖는 다중 출력 회귀(multivariate regression) 문제이다.

2. 데이터셋

2.1 환경: Gymnasium Pendulum-v1

단진자는 질량 $m = 1$ kg, 길이 $l = 1$ m의 강체 막대가 마찰 없는 축에 연결된 시스템이다. 중력 가속도 $g = 10$ m/s²이며, 연속 시간 운동 방정식은 다음과 같다:

$$\ddot{\theta} = (3g / 2l) \sin(\theta) + (3 / ml^2) * \text{torque}$$

Gymnasium 환경은 이 ODE를 Euler 적분($dt = 0.05$ s)으로 이산화하며, 각속도는 $[-8, 8]$ rad/s 범위로 제한된다.

2.2 데이터 수집 절차

500개의 에피소드(에피소드당 최대 200 스텝)에서 균일 랜덤 토크 행동($\tau \sim \text{Uniform}[-2, 2]$)으로 데이터를 수집하였다. 랜덤 탐색은 상태-행동 공간을 넓게 커버하도록 설계되었다. 각 스텝에서 `env.step()` 호출 전에 다음을 수행한다:

- 실제 각도 복원: $\theta = \arctan2(\sin\theta, \cos\theta)$
- Euler 다음 상태 계산 (Gym 업데이트와 동일하게 재현)
- RK4 다음 상태 계산 (dt 를 20 서브스텝으로 분할, 기준값)
- 오차 벡터 $y = \text{Euler} - \text{RK4}$ 를 회귀 목표로 기록

구분	값
총 샘플 수	100,000
에피소드 수	500
에피소드당 최대 스텝	200
입력 특성 수	4
출력 목표 수	2

표 1. 데이터셋 요약

2.3 입력 특성 및 출력 목표

변수	설명	역할
$\cos(\theta_t)$	진자 각도의 코사인	입력
$\sin(\theta_t)$	진자 각도의 사인	입력
$\dot{\theta}_t$	각속도 (rad/s)	입력
τ_t	적용 토크 (N·m)	입력
$\text{err_}\theta_t$	각도 오차: Euler - RK4 (rad)	출력 (목표)
$\text{err_}\dot{\theta}_t$	각속도 오차: Euler - RK4 (rad/s)	출력 (목표)

표 2. 입력 특성 및 출력 목표 변수 설명

2.4 학습/검증/테스트 분할

데이터셋을 무작위로 섞은 후 다음과 같이 분할하였다 (seed=42):

분할	샘플 수	비율
학습 (Train)	69,999	70%
검증 (Validation)	15,001	15%
테스트 (Test)	15,000	15%

표 3. 데이터셋 분할

3. 물리적 배경: Euler vs RK4 수치 적분

3.1 Euler 적분 (Gymnasium 내부 방식)

현재 상태 $(\theta, \dot{\theta})$ 와 토크 τ 가 주어지면, Gymnasium은 다음과 같이 상태를 갱신한다:

```
alpha = (3g/2l) * sin(theta) + (3/ml^2) * torque
thetadot' = clip(thetadot + alpha * dt, -8, 8)
theta' = theta + thetadot' * dt
```

Euler 적분은 1차 정확도를 가지며, 국소 절단 오차는 $O(dt^2)$, 전역 오차는 $O(dt)$ 로 누적된다.

3.2 RK4 적분 (기준값)

4차 Runge-Kutta 방법을 20개의 서브스텝($h = dt/20 = 0.0025$ s)으로 적용하여 수치적 기준값을 계산한다:

```
k1 = f(theta, thetadot)
k2 = f(theta+h/2*k1, thetadot+h/2*k1)
k3 = f(theta+h/2*k2, thetadot+h/2*k2)
k4 = f(theta+h*k3, thetadot+h*k3)
theta' = theta + (h/6)*(k1 + 2*k2 + 2*k3 + k4)
thetadot' = thetadot + (h/6)*(k1 + 2*k2 + 2*k3 + k4)
```

RK4는 4차 정확도를 가지며, 국소 절단 오차 $O(h^5)$, 전역 오차 $O(h^4)$ 로 Euler 대비 훨씬 정밀하다. $h = 0.0025$ s 조건에서 RK4 결과를 수치적 기준값으로 간주한다.

3.3 왜 오차가 학습 가능한가?

적분 오차는 ODE의 우변($\sin(\theta)$ 포함)을 통해 $(\theta, \dot{\theta}, \tau)$ 의 부드러운 함수로 표현된다. Euler 오차의 주도항은 해의 2차 미분에 비례하며, 이는 $\sin(\theta)$ 를 포함하는 매끄러운 비선형 함수이다. 따라서 MLP와 같은 함수 근사기로 오차 곡면을 정확히 학습할 수 있으며, 선형 모델은 각도 오차의 선형 성분만 포착 가능하다.

4. 방법론

동일한 학습/검증/테스트 분할과 동일한 전처리(StandardScaler, 입력 4개 전체 적용) 를 적용하여 두 모델을 학습하였다.

4.1 베이스라인: Linear Regression

MultiOutputRegressor로 두 개의 독립적인 LinearRegression 추정기를 각 목표 변수에 적용하였다. 목적 함수는 최소 제곱법이다:

$$\min_w ||Xw - y||_2^2$$

Linear Regression은 입력과 적분 오차 사이의 선형 관계를 가정한다. 실제 오차는 $\sin(\theta)$ 에 대한 비선형 의존성을 가지므로, 각속도 오차(err_theta_dot) 예측에서 선형 모델의 성능 상한선을 설정하는 베이스라인 역할을 한다.

4.2 MLP (Multi-Layer Perceptron)

3개의 은닉층을 가진 완전 연결 순방향 신경망을 사용하였다:

```
Input(4) -> Linear(128) -> ReLU -> Linear(64) -> ReLU -> Linear(32) -> ReLU  
-> Linear(2) [■ ■]
```

하이퍼파라미터	값
은닉층	3개 (128 -> 64 -> 32)
활성화 함수	ReLU
출력층	2 뉴런 (선형)
손실 함수	MSELoss
최적화 알고리즘	Adam (lr=1e-3)
에폭	100
배치 크기	512

표 4. MLP 하이퍼파라미터




그림 1. MLP 학습 곡선 (Train / Validation MSE Loss, 로그 스케일)

5. 실험 결과

5.1 정량적 성능 비교

테스트셋(15,000 샘플)에서 RMSE, MAE, R^2 를 각 목표 변수별로 측정하였다.

목표 변수	RMSE	MAE	R^2
err_theta	0.001089	0.000476	0.9936
err_theta_dot	0.033372	0.024832	0.5189
평균 (mean)	0.017230	0.012654	0.7562

표 5. Linear Regression 테스트 성능

목표 변수	RMSE	MAE	R^2
err_theta	0.000347	0.000236	0.9993
err_theta_dot	0.002474	0.000960	0.9974
평균 (mean)	0.001410	0.000598	0.9984

표 6. MLP 테스트 성능

5.2 모델 비교

모델	err_theta R^2	err_theta_dot R^2	평균 RMSE
Linear Regression	0.9936	0.5189	1.72e-02
MLP	0.9993	0.9974	1.41e-03

표 7. 모델별 테스트셋 성능 비교 요약




그림 2. 모델별 평균 RMSE 및 R^2 비교 (테스트셋)

5.3 예측값 vs. 실제값 산점도




그림 3. err_theta 예측값과 실제값의 산점도 (두 모델 비교)




그림 4. err_theta_dot 예측값과 실제값의 산점도 (두 모델 비교)

5.4 잔차 분포




그림 5. 각 목표 변수 및 모델별 잔차(Residual) 분포

6. 결과 분석 및 토론

6.1 어떤 모델이 가장 우수하며, 그 이유는?

MLP가 두 목표 변수 모두에서 Linear Regression을 크게 앞선다 (평균 $R^2 = 0.9984$ vs. 0.7562). 특히 err_theta_dot 에서 성능 격차가 두드러진다 ($R^2 = 0.9974$ vs. 0.5189). 이는 각속도 오차가 $\sin(\theta)$ 에 대해 강한 비선형 의존성을 갖기 때문이다. Linear Regression은 각도 오차(err_theta)에서는 비교적 좋은 성능을 보이는데 ($R^2 = 0.9936$), 이는 주도항이 θ 에 선형 비례하기 때문이다.

6.2 실패 사례 (Failure Modes)

큰 잔차는 주로 고속 각속도 영역($|\dot{\theta}| \geq 8$ rad/s 근방)에서 발생한다. 이 구간에서 Gymnasium의 clip 연산이 강한 비선형성을 만들어 두 모델 모두 충분히 학습하지 못한다. 또한 $\theta = 0$ (직립 위치) 근방에서 2차 미분값이 최대가 되어 Euler 오차 크기와 예측 난이도가 함께 증가한다. 잔차 히스토그램(그림 5)에서 MLP 잔차는 0 중심으로 좁게 분포하는 반면, Linear Regression은 err_theta_dot 에서 두꺼운 꼬리를 보인다.

6.3 학습이 어려운 이유

적분 오차의 절댓값 자체가 매우 작아(평균 $|\text{err_theta}| \sim 10^{-3}$ rad), 모델이 부동 소수점 입력으로부터 정밀한 함수를 학습해야 한다. 속도 경계에서의 clip 비선형성은 오차 곡면에 날카로운 불연속점을 만든다. 또한 두 목표 변수는 상관 관계가 있어(err_theta 는 err_theta_dot 의 적분), 다중 작업 학습 구조로 이를 활용할 수 있는 여지가 있다.

6.4 배포 가능성 평가

MLP는 두 목표 모두 $R^2 > 0.99$ 를 달성하여 오차 곡면을 잘 포착하고 있다. 평균 RMSE 1.4×10^{-3} 는 전형적인 200 스텝 궤적의 누적 범위(~ 10 rad)에 비해 작으므로, 오차 보상 적용 시 실질적인 궤적 개선이 가능하다. 단, 실제 배포를 위해서는 (1) 추론 지연 시간 프로파일링, (2) 피드백 루프 내 사용 시 페루프 안정성 평가, (3) 학습된 RL 정책 하에서의 검증이 추가로 필요하다.

6.5 향후 연구 방향

- 물리 기반 특성 추가: $\sin^2(\theta)$, $\dot{\theta} \cdot \sin(\theta)$ 등을 명시적 입력으로 추가하여 선형 모델 성능 향상.
- 시퀀스 모델: LSTM 또는 Transformer로 다중 스텝 오차 누적 예측.
- 페루프 보정: MPC 컨트롤러에 오차 모델을 통합하여 제어 성능 향상 여부 검증.
- 도메인 무작위화: 진자 질량 및 길이를 변화시켜 수집한 데이터로 파라미터 조건부 오차 모델 학습.

7. 결론

본 연구에서는 Gymnasium Pendulum-v1 환경의 Euler 적분과 RK4 적분 사이의 수치 적분 오차를 머신러닝 모델로 예측하였다. 랜덤 행동으로 수집한 10만 개의 상태-행동 샘플을 이용하여, 3층 은닉층 MLP [128→64→32]가 두 목표 변수(err_theta, err_theta_dot) 모두에서 $R^2 > 0.99$, 평균 RMSE 1.4×10^{-3} 를 달성하였다. 반면 Linear Regression은 각도 오차($R^2=0.9936$)에는 강하지만 각속도 오차($R^2=0.52$)에서는 비선형성을 포착하지 못한다.

이 결과는 수치 적분 오차가 상태-행동 공간의 매끄럽고 학습 가능한 함수임을 보여준다. 학습된 오차 모델은 sim-to-real 전이, 적응형 수치 적분, 물리 정보 기반 강화학습의 핵심 구성 요소로 활용될 수 있다.

참고문헌

- [1] Towers et al. Gymnasium: A Standard Interface for Reinforcement Learning Environments. arXiv:2407.17032, 2024.
- [2] Euler, L. Institutionum calculi integralis. 1768.
- [3] Runge, C. Uber die numerische Aufloesung von Differentialgleichungen. Math. Ann., 46:167-178, 1895.
- [4] Pedregosa et al. Scikit-learn: Machine Learning in Python. JMLR, 12:2825-2830, 2011.
- [5] Paszke et al. PyTorch: An Imperative Style, High-Performance Deep Learning Library. NeurIPS, 2019.

부록: 생성형 AI 활용 고지

Claude (claude-sonnet-4-6, Anthropic)를 다음 용도로 활용하였다: 프로젝트 폴더 구조 생성, Python 보일러플레이트 코드(ReportLab 레이아웃, python-pptx 슬라이드 생성, OpenCV 영상 렌더링), 코드 주석 작성. 문제 정의, 물리 방정식 도출, RK4 기준값 선택, 모델 아키텍처 결정, 결과 해석 등 모든 과학적 판단은 프로젝트 작성자가 직접 수행하였다. 생성된 코드는 모두 검토 및 검증 후 사용하였다.